

Notater: INF2220

Veronika Heimsbakk
veronahe@ifi.uio.no

9. desember 2014

Innhold

1	Kjøretid	3	4	Heap	12
1.2	Analyse av kjøretid	4	4.1	Eksempel på sletting i min-heap	12
1.3	Logaritmisk tid	4			
2	Trær	5	5	Grafer	13
2.2	Traversering	5	5.2	Terminologi	13
2.3	Terminologi	5	5.9	Topologisk sortering	13
2.8	Binært søketre	6	5.10.1	Algoritmer	14
2.9.1	Tidkompleksitet	6	5.11	Dijkstra	14
2.9.2	Søking	7	5.12	Prim	17
2.9.3	Sette inn	7	5.12.1	Framgangsmåte	17
2.10	Rød-svarte trær	7	5.13	Kruskal	18
2.11.1	Eksempel på innsetting	7	5.13.1	Framgangsmåte	18
2.12	B-trær	8	5.14	Dybde-først	19
3	Hashing	10	5.15	Biconnectivity	19
3.1	Hash-funksjoner	10	5.16	Strongly connected components (SCC)	20
3.2	Forskjellige typer hash-tabeller	10	6	Kombinatorisk søk	20
			6.1	Permutasjoner	21

7	Tekstalgoritmer	21	8.3	Heapsort	26
7.1	Brute force	21	8.4	Bubble sort	26
7.1.1	Analyse	21	8.5	Insertion sort	27
7.2	Boyer Moore	22	8.6	Selection sort	27
7.2.1	Eksempel: Bad character shift	22	8.7	Bucket sort	27
7.2.2	Eksempel: Good suffix shift	23	8.8	Radix sort	28
7.3	Huffman	24	9	Gamle eksamensoppgaver	29
7.3.1	Eksempel på Huffman- koding	24	9.1	Tekstalgoritmer (oppgave 7, H2011)	29
8	Sortering	24	9.2	Binære søketrær (oppgave 2, H2013)	31
8.1	Quicksort	24	9.3	Binære søketrær (oppgave 1, H2010)	32
8.2	Mergesort	26			

Introduksjon

Dette er notater til kurset INF2220–Algoritmer og datastrukturer[4] ved Universitetet i Oslo. Disse notatene er i all hovedsak basert på forelesningsfoiler, egne notater og læreboka. Brukes til repetisjon før eksamen og som notater under eksamen. Merk at notatene helt sikkert inneholder feil og mangler.

1 Kjøretid


Definisjon 1.1: O-notasjon La f og g være funksjoner $f, g : \mathcal{N} \rightarrow \mathcal{R}^+$. Sier at $f(n) = O(g(n))$ hvis det eksisterer positive heltall c og n_0 slik at for hvert heltall $n \geq n_0$,

$$f(n) \leq cg(n).$$

Når $f(n) = O(g(n))$, sier vi at $g(n)$ er **upper bound** for $f(n)$, eller mer presist at $g(n)$ er **asymptotic upper bound** for $f(n)$.

Funksjon	Navn
1	Konstant
$\log n$	Logaritmisk
n	Lineær
$n \log n$	
n^2	Kvadratisk
n^3	Kubisk
2^n	Eksponensiell
$n!$	

Tabell 1: Vanlige funksjoner for $O(n)$



Figur 1: Noen funksjoner for $O(n)$.

1.2 Analyse av kjøretid

Når man analyserer en algoritme, så må man se på *stegene* den bruker og analysere de hver for seg. Ta for eksempel denne kodesnutten:

```
for (i = 0; i < n; i++)  
  for (j = 0; j < m; j++)  
    array[i][j] = 0;
```

To steg:

1. Ytterste løkke går i $O(n)$.
2. Innerte løkke går i $O(m)$.

Dette gir $O(n) \times O(m) = O(n^2)$.

1.3 Logaritmisk tid

Algoritmer som tar logaritmisk tid, $O(\log n)$, finner man i operasjoner på binære trær, eller når man bruker binære søk og i *divide and conquer*-algoritmer.

```
for (i = 1; i < n; i = i * 2)  
  sum++;
```

Figur 2: Eksempel på løkke som går i $O(\log n)$.

2 Trær

Definisjon 2.1: Tre Et *tre* er en samling *noder*. Et ikke-tomt tre består av en **rot-node**, og null eller flere ikke-tomme **subtrær**. Fra roten går en **rettet kant** til roten i hvert subtre.

2.2 Traversering

Pre-order rot, venstre barn, høyre barn

In-order venstre barn, rot, høyre barn

Post-order venstre barn, høyre barn, rot

```
/* IN-ORDER TRAVERSAL */

public void inOrder (Node node) {
    if (node != null) {
        inOrder(node.left);
        // do something with the node
        inOrder(node.right);
    }
}

/* PRE-ORDER TRAVERSAL */

public void preOrder (Node node) {
    if (node != null) {
        // do something with the node
        preOrder(node.left);
        preOrder(node.right);
    }
}

/* POST-ORDER TRAVERSAL */

public void postOrder (Node node) {
    if (node != null) {
        postOrder(node.left);
        postOrder(node.right);
        // do something with the node
    }
}
```

2.3 Terminologi

Definisjon 2.4: Sti En sti fra node n_1 til n_k er definert som en sekvens n_1, n_2, \dots, n_k , slik at n_i er forelder til n_{i+1} for $1 \leq i \leq k$.

Definisjon 2.5: Lengde Antall kanter på veien; $k - 1$.


Definisjon 2.6: Dybde Definert av den unike veien fra roten til noden. Rotens dybde er 0.

Definisjon 2.7: Høyde Definert som lengden av den lengste veien fra noden til en løvnode. Alle løvnoder har høyde 0. Høyden til et tre er lik høyden til roten.

2.8 Binært søketre

Definisjon 2.9: Binært søketre Et binært søketre (BST) er et **ordnet** binært tre. Følgende kriterier må være oppfylt for at treet skal være et BST:

- Verdiene i **venstre** subtre er **mindre** enn noden i seg selv.
- Verdiene i **høyre** subtre er **større** enn noden i seg selv.
- Venstre og høyre subtre må også være binære søketrær.
- Hver node kan ha maksimum to barn.
- Det eksisterer en **unik** sti fra roten til enhver node i treet.



Figur 3: Eksempel på et binært søketre.

2.9.1 Tidkompleksitet

	Average	Worst case
Plass	$O(n)$	$O(n)$
Søk	$O(\log n)$	$O(n)$
Innsetting	$O(\log n)$	$O(n)$
Sletting	$O(\log n)$	$O(n)$

Tabell 2: Tidkompleksitet for BST.

2.9.2 Søking

```
function find(key, node):  
  if node = Null or node.key = key then  
    return node  
  else if key < node.key then  
    return find(key, node.left)  
  else  
    return find(key, node.right)
```

2.9.3 Sette inn

```
function insert(root, data):  
  if (!root)  
    root = new Node(data)  
  else if (data < root.data)  
    insert(root.left, data)  
  else if (data > root.data)  
    insert(root.right, data)
```


2.10 Rød-svarte trær

Definisjon 2.11: Rød-svart tre *En datastruktur som er et **selv-balanserende** binært søketre. Følgende skal gjelde for et rød-svart tre:*

1. *En node er enten rød eller sort.*
2. *Roten er sort.*
3. *Alle løvnoder (NIL) er sorte—alle løvnoder har samme farge som roten.*
4. *Enhver røde node må ha to sorte barn.*
5. *Enhver sti fra roten til en løvnode skal inneholde samme antall sorte noder.*

Dette sikrer at høyden på et slikt tre er maks $2 \times \log_2(N + 1)$.

2.11.1 Eksempel på innsetting



Figur 4: Eksempel på innsetting av tallene 41, 38, 31, 12, 19 og 8 i et rød-svart tre.

	Average	Worst case
Plass	$O(n)$	$O(n)$
Søk	$O(\log n)$	$O(\log n)$
Innsetting	$O(\log n)$	$O(\log n)$
Sletting	$O(\log n)$	$O(\log n)$

Tabell 3: Tidkompleksitet for rød-svarte trær.

2.12 B-trær

Kravene til et B-tre er følgende:

- Alle data er lagret i løvnode.
- Roten har mellom **2** og **M** barn.
- Alle løvnoder har mellom **L/2** og **L** elementer.


```

/* Red-black insertion */

public void put (Key key, Value val) {
    root = put(root, key, val);
    root.color = BLACK;
}

// insert key-value pair in subtree with root node
private Node put (Node node, Key key, Value val) {
    if (node == null) return new Node(key, val, RED, 1);

    int cmp = key.compareTo(node.key);
    if (cmp < 0)
        node.left = put(node.left, key, val);
    if else (cmp > 0)
        node.right = put (node.right), key, val);
    else
        node.val = val;

    if ( isRed(node.right) && !isRed(node.left) )
        node = rotateLeft(node);
    if ( isRed(node.left) && isRed(node.left.left) )
        node = rotateRight(node);
    if ( isRed(node.left) && isRed(node.right) )
        flipColors(node);
    node.N = size(node.left) + size(node.right) + 1;

    return node;
}

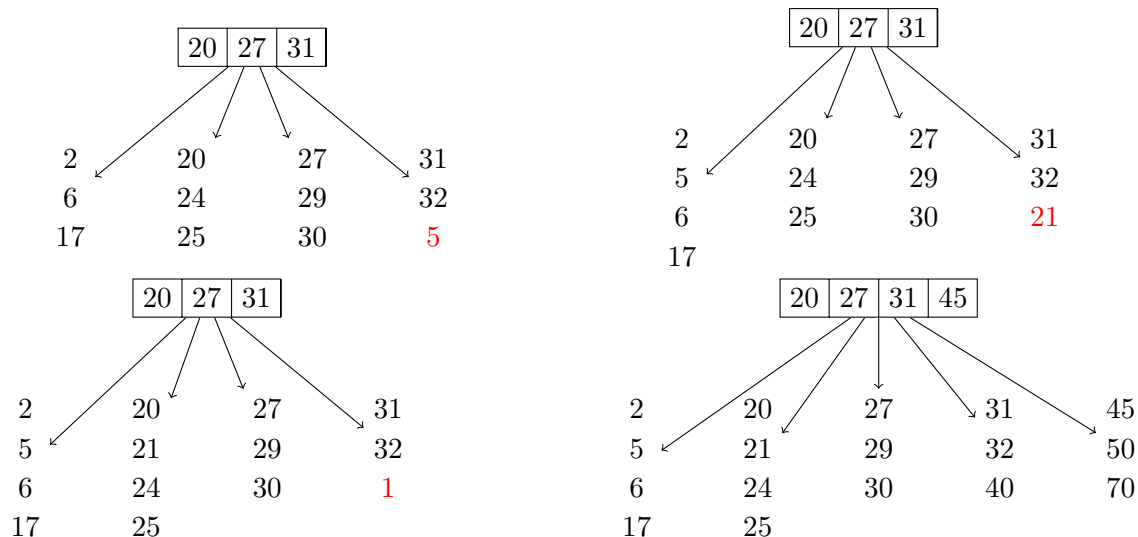
```

Figur 5: Eksempel på innsetting i rødsvert tre [1].

	Average	Worst case
Plass	$O(n)$	$O(n)$
Søk	$O(\log n)$	$O(\log n)$
Innsetting	$O(\log n)$	$O(\log n)$
Sletting	$O(\log n)$	$O(\log n)$

Tabell 4: Tidkompleksitet for B-trær.

Eksempel på innsetting i B-tre Sette inn tallene 2, 6, 17, 20, 24, 25, 27, 29, 30, 31, 32, 5, 21, 1, 40, 45, 50, 70 med kravene $M = 5$, $L = 5$.



Når den ene løvnoden fylles opp til maks antall elementer, så må den splittes i halv til to nye løvnoder.

3 Hashing

Idéen i hashing er å lagre alle elementene i en array (hashtabell) og la verdien i elementet x bestemme indeksen til x i hashtabellen. Egenskaper til en god hash-funksjon er at den er rask å beregne, kan gi alle mulige verdier fra 0 til tabellens størrelse -1 . Og den gir en god fordeling utover tabellindeksene. En hashtabell tilbyr innsetting, sletting og søking med konstant tid.

3.1 Hash-funksjoner

Eksempel med heltall som nøkkel, begrenset antall tabellindekser. La hashfunksjonen være $\text{hash}(x, \text{tableSize}) = x \bmod \text{tableSize}$. Husk at hvis `tableSize` er 10 og alle nøklene slutter på 0, vil alle elementene havne på samme indeks. Huskeregel for dette: la alltid tabellstørrelsen være et primtall. Funksjonen under summerer verdiene til hver bokstav. Dette er en dårlig fordeling dersom tabellstørrelsen er stor.

```
int hash (String key, int tableSize) {
    int hashValue = 0;
    for (i = 0; i < key.length(); i++)
        hashValue += key.charAt(i);
    return (hashValue % tableSize);
}
```

3.2 Forskjellige typer hash-tabeller

- **Seperate chaining** er en hash-tabell hvor hver indeks peker til en liste av elementer.
- **Probing** er rommet mellom hver indeks.

- *Lineær probing*; intervallene er satt (normalt 1).
- *Kvadratisk probing*; intervallene øker med å legge til et kvadratisk polynom ved startverdi gitt av hashberegningen.
- *Dobbel hashing*; intervallene er gitt av en annen hash-funksjon.

Index	Linear probing	Quadratic probing	Separate chaining
0	9679	9679	
1	4371	4371	
2	1989		
3	1323	1323	1323 → 6173
4	6173	6173	4344
5	4344	4344	
6			
7			
8		1989	
9	4199	4199	4199 → 9679 → 1989

Tabell 5: Eksempel på hashing.

I tabell 3.2 har vi forskjellige hash-tabeller på tallene $\{4371, 1323, 4199, 4344, 9679, 1989\}$ som skal settes inn i en tabell på størrelse 10, og med hash-funksjon $H(X) = X \bmod 10$.

Lineær probing her tar man tallet og setter inn i hash-funksjonen. Så for første tall (4371) vil indeksen bli 1. Hvis indeksen er opptatt, så plusser man på 1.

Kvadratisk probing er så og si det samme, men i stedet for å legge til 1 hvis indeksen er opptatt, så legger man på $1^2, 2^2, 3^2, \dots$

Dobbel probing her lager vi en ny hash-funksjon når indeksen krasjer. Da tar man et tall P , som er det største primtallet som er mindre enn tabellstørrelsen. Dette brukes til å lage en ny hash-funksjon $H(X) = R - (X \bmod R)$.

Separate chaining her legges det nye tallet på i en liste om indeksen er opptatt fra før.


4 Heap

En **binær heap** er et komplett binærtre, hvor barna alltid er større eller lik sine foreldre. Og et komplett binærtre har følgende egenskaper:


- Treet vil være i perfekt balanse.
- Løvnoder vil ha høydeforskjell på maksimalt 1.
- Treet med høyden h har mellom 2^h og $2^{h+1} - 1$ noder.
- Den maksimale høyden på treet vil være $\log_2(n)$.

4.1 Eksempel på sletting i min-heap



Skal gjøre operasjonen `deleteMin()` på følgende heap.



Begynner med å slette rot noden 1. Og flytter siste element (8) opp til rot posisjon.



Får da dette resultatet. Og vi må nå flytte 8 ned til riktig posisjon.



5 Grafer

Definisjon 5.1: Graf En **graf** \mathcal{G} består av en ikke-tom mengde noder \mathcal{V} og en mengde kanter \mathcal{E} , slik at enhver kant forbinder nøyaktig to noder med hverandre eller en node med seg selv.

5.2 Terminologi

Definisjon 5.3: Vektet En graf er vektet dersom hver kant har en tredje komponent. En verdi langs kanten.

Definisjon 5.4: Sti En sti gjennom grafen er en sekvens av noder $v_1, v_2, v_3, \dots, v_n$, slik at $(v_i, v_{i+1}) \in \mathcal{E}$ for $1 \leq i \leq n - 1$.

Definisjon 5.5: Lengde Lengden til stien er lik antall kanter på stien.


Definisjon 5.6: Løkke Ei løkke i en rettet graf er en vei med lengde ≥ 1 , slik at $v_1 = v_n$. Løkken er enkel dersom stien er enkel.

Definisjon 5.7: Asyklisk En rettet graf er asyklisk dersom den ikke har noen løkker. DAG (Directed, Acyclic Graph).

Definisjon 5.8: Sammenhengende En urettet graf er sammenhengende dersom det fins en sti fra hver node til alle andre noder.

5.9 Topologisk sortering

Definisjon 5.10: Topologisk sortering En topologisk sortering (topologisk orden) av en rettet graf er en lineær ordning av nodene, slik at for hver rettet kant $\langle u, v \rangle$ fra node u til node v , så kommer u før v i ordningen.



Figur 6: Eksempelfigur for topologisk sortering.

I figur 6 har vi følgende lovlige topologiske sorteringer:

- Q, A, B, J, Z, P
- Q, B, A, J, Z, P
- Q, A, B, Z, J, P
- Q, B, A, Z, J, P

5.10.1 Algoritmer


De vanligste algoritmene for topologisk sortering har lineær kjøretid i antall noder, pluss antall kanter; $O(|V| + |E|)$. En av disse kommer det et eksempel på her.

```
L <- empty list that will contain the sorted elements
S <- set of all nodes with no incoming edges

while S is non-empty do:
  remove a node n from S
  insert n into L
  for each node m with an edge e from n to m do:
    remove edge e from the graph
    if m had no other incoming edges then:
      insert m into S
if graph has edges then:
  return error (graph has at least one cycle)
else
  return L (a topologically sorted order)
```

5.11 Dijkstra

1. For alle noder, sett avstanden fra startnoden s lik ∞ . Merk noden som *ukjent*.
2. Sett avstanden fra s til seg selv lik 0.
3. Velg en ukjent node v med minimal avstand fra s og marker v som kjent.
4. For hver ukjente nabo w til v : Dersom avstanden vi får ved å følge veien gjennom v , er kortere enn den gamle avstanden til s . Redusér avstanden til s for w og sett bakoverpekeren i w til v .
5. Akkurat som for uvektede grafer, ser vi bare etter potensielle forbedringer for naboer som ennå ikke er kjent.



Figur 7: Eksempelgraf for Dijkstra.

V	Init			1			3		
	known	dist.	from	known	dist.	from	known	dist.	from
1	F	0	0	T	0	0	T	0	0
2	F	–	0	F	5	1	F	5	1
3	F	–	0	F	2	1	T	2	1
4	F	–	0	F	4	1	F	4	1
5	F	–	0	F	–	0	F	–	0
6	F	–	0	F	–	0	F	9	3
7	F	–	0	F	–	0	F	–	0

V	6			4			7		
	known	dist.	from	known	dist.	from	known	dist.	from
1	T	0	0	T	0	0	T	0	0
2	F	5	1	F	5	1	F	5	1
3	T	2	1	T	2	1	T	2	1
4	F	4	1	T	4	1	T	4	1
5	F	–	0	F	–	0	F	–	0
6	T	9	3	T	6	4	T	6	4
7	F	–	0	F	10	4	T	10	4

V	2					
	known	dist.	from			
1	T	0	0			
2	T	5	1			
3	T	2	1			
4	T	4	1			
5	F	–	0			
6	T	6	4			
7	T	10	4			

Tabell 6: Tabell til Dijkstra-algoritmen på grafen i figur 7.

Algoritmen Her er pseudokoden for Dijkstra.

```
function Dijkstra (Graph, source):
  for each vertex v in Graph:
    distance[v] := infinity
    visited[v] := false;
    previous[v] := undefined;


  distance[source] = 0;
  insert source into Q;

  while Q is not empty:
    u := vertex in Q with smallest distance in distance[]
      and has not been visited;
    remove u from Q;
    visited[u] := true;

    for each neighbour v of u:
      alt := distance[u] + dist_between(u,v);
      if alt < dist[v];
        dist[v] := alt;
        previous[v] := u;
        if !visited[v]:
          insert v into Q;

  return distance;
end function;
```


5.12 Prim



Figur 8: Eksempelgraf for Prim og Kruskal.

5.12.1 Framgangsmåte

1. Initialiser et tre med en enkelt node, valgt tilfeldig fra grafen.
2. Gro treet med én kant (av de kantene som går til en node som ikke er med i treet), finn den kanten med minst vekt og legg den inn i treet.
3. Gjenta steg 2 til alle nodene er i treet.


```

PRIM(G, w, r)
  for each u in G.V
    u.key = infinite
    u.parent = NIL
  r.key = 0
  Q = G.V
  while Q is not empty
    u = extract-min(Q)
    for each v in G.Adj[u]
      if (v in Q) and w(u,v) < v.key
        v.parent = u
        v.key = w(u,v)

```

Når man utfører Prims algoritme på grafen i figur 8, så blir resultatet følgende:

MERK: løsningen i figur 9 er *ikke* unik. Eneste måten man kan få et unikt resultat er om alle vektene på kantene er unike. Det samme gjelder for Kruskal.



Figur 9: Eksempelgraf 8 etter Prims algoritme.

	avs.	fra
A	0	–
B	3	A
C	2	B
D	8	H
E	3	F
F	1	B
G	2	C
H	4	E
I	3	F
	<hr/> 26 <hr/>	

Tabell 7: Tabell for Prims algoritme på figur 9.

5.13 Kruskal

5.13.1 Framgangsmåte


- Lag en *skog* \mathcal{F} (en sett med trær), hver node i grafen er et separat tre.
- Lag et sett \mathcal{S} som inneholder alle kantene til grafen.
- Så lenge \mathcal{S} ikke er tom og \mathcal{F} ikke ennå er et spanning-tre:
 - Fjern en kant men lavest vekt fra \mathcal{S} .
 - Hvis kanten kobler to forskjellige trær, legg den i skogen slik at de to blir ett tre.

Når algoritmen er ferdig, så former skogen et minimum spanning-tre for grafen.

```

KRUSKAL (G):
  A = empty
  for each v in G.V:
    MAKE-SET(v)
  for each (u,v) ordered by weight(u,v), increasing:
    if FIND-SET(u) not in FIND-SET(v):
      A = A union {(u,v)}
      UNION(u,v)
  return A


```

Figur 12: DFS spenntre for grafen i figur 11.

5.16 Strongly connected components (SCC)

Definisjon 5.16.1. Gitt en rettet graf $\mathcal{G} = (\mathcal{V}, \mathcal{E})$. En **strongly connected component** av \mathcal{G} er et maksimalt sett av noder $U \subseteq \mathcal{V}$. For alle $u_1, u_2 \in U$ har vi at $u \rightarrow^* u_2$ og $u_2 \rightarrow^* u_1$.



Figur 13: Eksempel på graf med noen SCCer.

Måten man finner ut om en graf har SCCer er:

1. Gjør en DFS på grafen. Nummerér nodene.
2. Reverser grafen og gjør en DFS i **avtagende** rekkefølge.

Man finner da gruppene med SCCer, det er grupper hvor alle nodene kan nå hverandre. I grafen i figur 13 så er SCCene $\{\{a, b, e\}, \{f, g\}, \{c, d, h\}\}$.

6 Kombinatorisk søk

Kombinatorisk søk-algoritmer er ofte problemer som er NP-hard. Men problemene kan løses effektivt om de brytes ned. Et eksempel på et problem hvor man får bruk for kombinatorisk søk er å plassere åtte dronninger på et sjakkboard.

6.1 Permutasjoner

En permutasjon er å rearrangere objekter. For eksempel så fins det seks permutasjoner av settet $\{1,2,3\}$, som er: $(1,2,3)$, $(1,3,2)$, $(2,1,3)$, $(2,3,1)$, $(3,1,2)$ og $(3,2,1)$.

Alle mulige permutasjoner av tallene fra 0 til $n - 1$.

```
class Gen {
    int[] p; int n;
    boolean[] used;

    Gen (int i) {
        n = i; p = new int[n];
        used = new boolean[n];

        for (int j = 0; j < n; j++) {
            used[j] = false;
        }
    }

    void gen(int place) {
        for (int number = 0; number < n; number++) {
            if (!used[number]) {
                used[number] = true;
                p[place] = number;

                if (place < n-1) { gen(place+1); }
                else { <deliver p to further use.> }
                used[number] = false;
            }
        }
    }
}
```

7 Tekstalgoritmer

7.1 Brute force

Brute force metoden sjekker en og en karakter i teksten med nålen, og flytter med 1 om det er mismatch.

7.1.1 Analyse

Worst case så får vi mismatch $(n - m)$ ganger og suksess $(n - m) + 1$ ganger. Totale sammenligninger er $((n - m) + 1 \times m)$ som gir kjøretid $O(n^2)$.

7.2 Boyer Moore

- Først må man lage «bad match table».
- Sammenligne nålen med teksten, starter med karakteren lengst til høyre i nålen.
- Hvis mismatch, flytt nålen fram iht. verdien i tabellen.

7.2.1 Eksempel: Bad character shift

Pattern (nål) tooth

Tekst trusthardtoothbrushes

1. Konstruere «bad match table».

$$\text{value} = \text{length} - \text{index} - 1$$

Alle andre bokstaver har verdi lik lengden.

	T	O	O	T	H
index:	0	1	2	3	4

Lengden på denne nålen er 5. Finner verdiene ved å bruke $\text{value} = \text{length} - \text{index} - 1$.

$$\begin{array}{lcl} \text{T} = & 5 - 0 - 1 & = 4 \\ \text{O} = & 5 - 1 - 1 & = 3 \\ \text{O} = & 5 - 1 - 2 & = 2 \quad \text{Erstatter her forrige verdi av O med ny verdi til O.} \\ \text{T} = & 5 - 3 - 1 & = 1 \quad \text{Erstatter her forrige verdi av T med ny verdi til T.} \\ \text{H} = & 5 & \quad \text{Verdien skal ikke være mindre enn 1. Får da verdi lik lengden.} \end{array}$$

Bokstav	T	O	H	*
Verdi	1	2	5	5

	T	R	U	S	T	H	A	R	D	T	O	O	T	H	B	R	U	S	H	E	S
1.	T	O	O	T	H																
2.		T	O	O	T	H															
3.							T	O	O	T	H										
4.								T	O	O	T	H									
5.									T	O	O	T	H								

I steg **1.** får vi mismatch på H, fordi den ikke er det samme som T. Da må vi slå opp i tabellen på den bokstaven som *vi møter i teksten*, og hoppe fram tilsvarende antall steg. I første tilfellet skal vi hoppe 1 plass fram (for 1 er verdien til T).

Sjekker på nytt i steg **2.**, her får vi match på T og H, men mismatch på O. Da hopper vi S-plasser frem. Siden S ikke er med i tabellen vår (eller den er med som *, som er alle andre bokstaver), så hopper vi 5 plasser frem.

I steg **3.** får vi mismatch på H mot O, og må hoppe O-plasser frem—altså 2. I steg **4.** er det mismatch mellom H og T, vi hopper T-plasser frem—altså 1. Og vips! Så har vi funnet nålen i teksten vår!

Analyse Worst case er det samme som brute force. Input tekst 1^n kjører n ganger, og nål $011\dots 1$ kjører m ganger. Dette gir $O(nm)$. Best case har input tekst 1^n og nål 0^m , som gir $O(n/m)$. Average case er $O(m/|\Sigma|)$, raskere enn brute force.

7.2.2 Eksempel: Good suffix shift

Konstruere *good suffix table* for nålen TCCTATTCTT.

1. Sjekker først *ikke*-T, det er to shift før man finner dette.

TCCTATTCT**T**
--TCCTATT**C**TT

2. Så sjekker man *ikke*-TT. Dette finner man etter ett shift.

TCCTATTCT**TT**
-TCCTATT**C**TT

3. For å finne *ikke*-CTT må vi flytte 3 steg; til ATT.

TCCTATT**CTT**
---TCCT**A**TTCTT

4. Så kommer vi til *ikke*-TCTT. Denne eksisterer ikke, MEN om nålen har lik suffix som prefiks (her T som start og slutt), så flytter vi bare fram til prefiksen. Da må vi flytte nålen 9 hakk, selv om lengden er 10.

TCCTATTCT**T**
-----**T**CCTATTCTT

Alle de neste shiftene vil også være dette, fordi de får ingen andre treff i nålen.

Vi får da følgende good suffix table:

index	mismatch	shift
0	T	2
1	TT	1
2	CTT	3
3	TCTT	9
4	TTCTT	9
5	ATTCTT	9
6	TATTCTT	9
7	CTATTCTT	9
8	CCTATTCTT	9
9	TCCTATTCTT	9

Tabell 8: Eksempel på good suffix table.

7.3 Huffman

Regler

1. Hvert tegn som forekommer i teksten skal ha sin egen entydige kode.
2. Ingen kode er prefiks i en annen kode.

Algoritme

- Lag en *frekvenstabell* for alle tegn som forekommer i teksten.
- Betrakt hvert tegn som en node, og legg dem inn en prioritetskø P med frekvensen som vekt.
- Mens P har mer enn ett element:
 - Ta ut de to minste nodene fra P.
 - Gi dem en felles foreldrenode med vekt lik summen av de to noderes vekter.
 - Legg foreldrenoden inn i P.
- Huffmankoden til et tegn (løvnode) får vi ved å gå fra roten og gi en '0' når vi går til venste og '1' når vi går til høyre.
- Resultatfilen består av to deler: en tabell over Huffmankoder med tilhørende tegn og den Huffmankodede datafilen.

7.3.1 Eksempel på Huffmankoding


Karakter	Kode	Frekvens
n	11	4
c	01	3
o	101	2
r	100	2
e	001	2
u	000	1

Tabell 9: Eksempel på en Huffmantabell.

8 Sortering

8.1 Quicksort

Quicksort er en *divide and conquer* algoritme. Den deler først en stor array inn i to mindre sub-arrayer: de mindre og de større verdiene. Sorterer så sub-arrayene rekursivt.



Figur 14: Huffmantreet for tabellen i tabell 9.

Algoritme	Tid			Rom
	Best	Average	Worst	Worst
Quicksort	$O(\log(n))$	$O(\log(n))$	$O(n^2)$	$O(n)$
Mergesort	$O(\log(n))$	$O(\log(n))$	$O(\log(n))$	$O(1)$
Heapsort	$O(\log(n))$	$O(\log(n))$	$O(\log(n))$	$O(n)$
Bubble sort	$O(n)$	$O(n^2)$	$O(n^2)$	$O(n)$
Insertion sort	$O(n)$	$O(n^2)$	$O(n^2)$	$O(1)$
Selection sort	$O(n^2)$	$O(n^2)$	$O(n^2)$	$O(1)$
Bucket sort	$O(n + k)$	$O(n + k)$	$O(n^2)$	$O(nk)$
Radix sort	$O(nk)$	$O(nk)$	$O(nk)$	$O(n + k)$

Tabell 10: Kompleksiteten til forskjellige sorteringsalgoritmer.

1. Velg et element, kalt *pivot*, fra arrayen.
2. Reorder arrayen slik at alle elementene med vardier mindre enn pivot kommer før pivot, og alle elementer større enn pivot kommer etter. Pivot er på sin sluttplass. Dette kalles *partisjonering*.
3. Rekursivt gjenta stegene over på sub-arrayene med mindre og større verdier.

```

quicksort(A, i, k):
    if i < k:
        p := partition(A, i, k)
        quicksort(A, i, p-1)
        quicksort(A, p+1, k)

partition(array, left, right)
    pivotIndex := choosePivot(array, left, right)
    pivotValue := array[pivotIndex]
    swap array[pivotIndex] and array[right]
    storeIndex := left
    for i from left to right - 1
        if array[i] < pivotValue
            swap array[i] and array[storeIndex]
            storeIndex := storeIndex+1
    swap array[storeIndex] and array[right]

```

```
return storeIndex
```

8.2 Mergesort

Mergesort er en *divide and conquer* algoritme.

1. Del den usorterte listen i n sublister, hvor hver inneholder *ett* element.
2. Smelt sammen sublistene for å lage nye sorterte sublister til det er bare ei liste igjen. Dette er den sorterte listen.

8.3 Heapsort

Heapsort er en *in-place* algoritme, men den er ikke en *stable sort*.

Først bygger man en heap ut av dataene. Ofte plassert i en array etter kravene for et komplett binært tre. Roten er lagret på index 0, hvis i er indeksen til *denne* noden, så:

```
iParent      = float((i-1)/2)
iLeftChild   = 2*i+1
iRightChild  = 2*i+2
```

I det andre steget lager man en sortert array ved gjentatte ganger fjerne største element fra heapen (roten), og sette det inn i arrayen. Heapen er oppdatert etter hver sletting, for å opprettholde kravene. Når alle elementene er slettet fra heapen, er resultatet en sortert array.

8.4 Bubble sort

Bubble sort, også kalt sinking sort, er en sammenlignings-sorteringsalgoritme. Den er for treig for all praktisk bruk, til og med treigere enn insertion sort.

```
bubblesort(A : list of sortable items)
  n = length(A)
  do:
    swapped = false
    for i = 1 to n-1 inclusive do
      if A[i-1] > A[i] then
        swap(A[i-1], A[i])
        swapped = true
    while not swapped
```

8.5 Insertion sort

Enkel sorteringsalgoritme, som ikke er særlig effektiv på større lister. Da er algoritmer som quicksort, heapsort osv å foretrekke.

```
for i = 1 to length (A)
  x = A[i]
  j = i
  while j > 0 and A[j-1] > x
    A[j] = A[j-1]
    j = j-1
  A[j] = x
```

8.6 Selection sort

Selection sort er en *in-place* sammenlignings-algoritme.

La \mathcal{L} være et ikke-tomt sett og $f : \mathcal{L} \rightarrow \mathcal{L}$, slik at $f(\mathcal{L}) = \mathcal{L}'$ hvor:

1. \mathcal{L}' er en permutasjon av \mathcal{L} ,
2. $e_i \leq e_{i+1}$ for alle $e \in \mathcal{L}'$ og $i \in \mathbb{N}$,
3. $f(\mathcal{L}) = \begin{cases} \mathcal{L} & \text{if } |\mathcal{L}| = 1 \\ \{s\} \cup f(\mathcal{L}_s), & \text{ellers} \end{cases}$
4. s er det *minste elementet* i \mathcal{L} , og
5. \mathcal{L}_s er settet med elementer av \mathcal{L} uten instansen av det minste elementet fra \mathcal{L} .

Algoritmen finner minste verdi, bytter denne med verdien i første posisjon, og repeterer disse stegene for resten av listen.

8.7 Bucket sort

Bucket sort, eller bin sort, er en *distribution sort* algoritme.

1. Sett opp en array med tomme «bøtter».
2. **Scatter**: gå over den originale arrayen, og putt hvert objekt i sin bølge.
3. Sortert hver ikke-tomme bølge.
4. **Gather**: besøk alle bøttene etter orden, og putt alle elementer tilbake i den originale arrayen.

```
function bucketSort(array, n)
  buckets <- new array of n empty lists
  for i = 0 to (length(array) - 1) do
    insert array[i] into buckets[mbits(array[i], k)]
  for i = 0 to n - 1 do
    nextSort(buckets[i]);
  return the concatenation of buckets[0], ..., buckets[n-1]
```

8.8 Radix sort

Radix sort er en *non-comparative* integer sorterings algoritme. Er i samme familie som bucket sort.


1. Ta det minst signifikante tallet av hver nøkkel.
2. Gruppér nøklene basert på dette tallet.
3. Gjenta til grupperingsprosessen med hvert høyere signifikante bit.

Eksempel Original, usortert lise: 170, 45, 75, 90, 802, 2, 24, 66

- Sortere på minst signifikante (1-er plassen): 170, 90, 802, 2, 24, 45, 75, 66
- Sortere på 10-er plassen: 802, 2, 24, 45, 66, 170, 75, 90
- Sortere på 100 plassen: 2, 24, 45, 66, 75, 90, 170, 802

9 Gamle eksamensoppgaver

Ved å gå gjennom alle gamle eksamensoppgaver (fra 2009 til 2013) og notere hvor mange poeng hver «pensum kategori» teller, så har jeg kommet fram til følgende skjema:



Det er helt klart binære trær, grafer, tekstalgoritmer, sortering og implementasjonsoppgaver som dominerer. I denne seksjonen skal jeg svare på noen eksamensoppgaver.

9.1 Tekstalgoritmer (oppgave 7, H2011)

7a) Beregn *good suffix shift* av nålen: a b c a b c a c a b I indeks 1, så ser vi at ikke-a b ikke eksisterer i nåla, dermed må vi flytte lik lengden av nåla som er 10. I indeks 2 finner vi at nålens prefiks a b er lik nålens suffix. For mismatch etter denne trenger vi ikke shifte lenger enn til når prefiks og suffix er justert til hverandre, altså shifte 8.

indeks	mismatch	shift
0	b	1
1	ab	10
2	cab	8
3	acab	5
4	cacab	8
5	bcacab	8
6	abcacab	8
7	cabcacab	8
8	bcabcacab	8
9	abcabcacab	8

7b) En mismatch er funnet under leting etter nålen a b c a b c a c a b som angitt nedenfor:

Høystakk: a a c a b c a a b c a b c a b c a c a b
 Nål: a b c a b c a c a b

Hvor i høystakken vil *Boyer Moore*-algoritmen lete etter neste match? (dvs. hvor langt vil Boyer Moore skifte nålen etter denne mismatch?) Med Boyer Moore bad character shift vil den gjøre et shift på 2 for å lete etter neste match. Shift-tabellen må konstrueres:

a	b	c	*
1	5	2	10

Hvor * er alle andre karakterer enn a, b eller c. Og verdien er $\text{value} = \text{length} - \text{index} - 1$. Hvor length er lengden av nåla = 10. Og indeks er karakterens indeks i nåla:

Karakter	a	b	c	a	b	c	a	c	a	b
Indeks	0	1	2	3	4	5	6	7	8	9

Verdien i shift-tabellen skal være lavest mulig, men kan ikke være mindre enn 1. For a, b og c blir det:

a	$10 - 8 - 1$	= 1
b	$10 - 4 - 1$	= 5
c	$10 - 7 - 1$	= 2


I oppgaven er det mismatch på c i høystakken. Og siden shift-verdien til c er 2, så flyttes nåla 2 nedover høystakken for neste match.

Høystakk: a a c a b c a a b c a b c a b c a c a b
 Nål: a b c a b c a c a b
 Shift: . . a b c a b c a c a b

7c) Lag en Huffmankode for strengen nonconcurrency. Vis dekodningstabellen. Koden er ikke unik. For at koden skal være unik, så må karakterenes frekvens også være unik. Et eksempel kan være at u og o er naboer istedenfor u og e, da ville o hatt koden 001, og ikke 101.

Huffmann-treet bygges ved å sette sammen de to og to laveste frekvensene til en ny frekvensforelder. Dette gjør at den karakteren med høyst frekvens får korteste kode. Kantene til høyre telles som '1', og kantene til venstre som '0'.

Karakter	Kode	Frekvens
n	11	4
c	01	3
o	101	2
r	100	2
e	001	2
u	000	1



9.2 Binære søketrær (oppgave 2, H2013)

2a) Gitt et binært søketre og et heltall x . Metoden find skal returnere noden V som har verdi lik x (du kan forutsette at den finnes). Fullfør de tre kodelinjene som starter med return. .

```


class BinNode {
    int value;
    BinNode leftChild;
    BinNode rightChild;

    BinNode find (int x) {
        if (value == x)
            return this;
        else if (value < x)
            return rightChild.find(x);
        else
            return leftChild.find(x);
    }
}

```


9.3 Binære søketrær (oppgave 1, H2010)

1a) Tegn treet du får ved å sette disse verdiene: 9, 1, 3, 10, 4, 6, 7 og 8, inn i et tomt binært søketre (i den rekkefølgen).



1b) Er det mulig å finne elementer i binærtreet fra oppgave 1a i logaritmisk (\log_2) tid? **Begrunn svaret.** Nei. Fordi treet er ute av balanse. Treet inneholder 8 elementer, og $\log_2(8) = 3$, og treet i oppgave 1a) er høyere enn det.

1c) Fjern verdiene 1 og 3 fra binærtreet. Tegn binærtreet etter at de to elementene er blitt fjernet.



Referanser

- [1] Unknown, *RedBlackBST.java*. algs4.cs.princeton.edu, <http://algs4.cs.princeton.edu/33balanced/RedBlackBST.java.html>
- [2] Unknown, *Boyer Moore Horspool Algorithm*. <https://www.youtube.com/watch?v=PHXAOKQk2dw>
- [3] Unknown, *Sorting algorithm*. http://en.wikipedia.org/wiki/Sorting_algorithm
- [4] Insitutt for informatikk, Universitetet i Oslo, *INF2220–Algoritmer og datastrukturer*. <http://www.uio.no/studier/emner/matnat/ifi/INF2220/>